


TP558 - Tópicos avançados em
Machine Learning:

Particle Swarm Optimization




Abertura: Por que a otimização?

ABERTURA

Problemas reais podem ter espaços de busca grandes, não lineares e multimodais.

- O objetivo é encontrar soluções que minimizem ou maximizem uma função de desempenho.
- Métodos populacionais exploram várias regiões do espaço simultaneamente.
- PSO usa memória individual + informação social para orientar essa busca.



Introdução do artigo: origem e objetivo

INTRODUÇÃO DO ARTIGO



Introdução do artigo: Origem e objetivo

INTRODUÇÃO DO ARTIGO

1995 · origem

Kennedy e Eberhart partiram de analogias de interação social e de simulações de bandos de pássaros. A ideia evoluiu para um método de otimização.

2007 · panorama

Poli, Kennedy e Blackwell sintetizam a evolução do PSO: dinâmica, topologias, variantes, teoria, aplicações e problemas em aberto.

Natureza do artigo

É um overview/review, não um experimento único. O foco está em organizar e interpretar a literatura acumulada.


Principais contribuições:

1. Mapeamento rigoroso das variantes do algoritmo (inércia, constrição, FIPS).
2. Síntese do comportamento dinâmico e topologias de rede do enxame.
3. Compilação de aplicações reais (engenharia, robótica, redes).

Fundamentação teórica: inteligência de enxame


FUNDAMENTAÇÃO TEÓRICA

Uma partícula isolada tem pouca capacidade de busca. O comportamento útil aparece quando as partículas trocam informação.



Fundamentação teórica: Anatomia de uma partícula

FUNDAMENTAÇÃO TEÓRICA



x_i • Posição atual

Solução candidata avaliada nesta iteração.

p_i • Personal best

Melhor posição já encontrada pela própria partícula.

p_g • Best neighbor

Melhor posição conhecida em sua vizinhança social.

v_i • Velocidade

Passo e direção do próximo movimento.

Fundamentação teórica: equação original do PSO

FUNDAMENTAÇÃO TEÓRICA

$$v_i \leftarrow v_i + U(0, \phi_1) \odot (p_i - x_i) + U(0, \phi_2) \odot (p_g - x_i)$$

$$x_i \leftarrow x_i + v_i$$

1 · Movimento anterior

v_i preserva parte da direção e do passo que a partícula já possuía.

2 · Componente cognitiva

$(p_i - x_i)$ aponta da posição atual para a melhor experiência individual.

3 · Componente social

$(p_g - x_i)$ aponta para a melhor informação disponível na vizinhança.

$U(0, \phi)$ introduz aleatoriedade em cada dimensão e a cada iteração.

Fundamentação teórica: ciclo de atualização


FUNDAMENTAÇÃO TEÓRICA



Fundamentação teórica: exploration × exploitation


FUNDAMENTAÇÃO TEÓRICA

O desempenho depende do equilíbrio entre explorar novas regiões e refinar regiões promissoras.



EXPLORATION

ϕ_1 · Força cognitiva



EXPLOITATION

ϕ_2 · Força social

V_{max} · Limite de passo

Fundamentação teórica:

FUNDAMENTAÇÃO TEÓRICA

$$v_i \leftarrow \omega v_i + U(0, \phi_1) \odot (p_i - x_i) + U(0, \phi_2) \odot (p_g - x_i)$$

ω regula quanto da velocidade anterior é preservado.

ω Relativamente alto

Maior persistência do movimento. Favorece exploração mais ampla e menor dissipação.

ω Relativamente baixo

Maior amortecimento. Favorece busca local e refinamento próximo a regiões promissoras.

Estratégia discutida no artigo: reduzir aproximadamente $\omega = 0,9 \rightarrow 0,4$ ao longo da execução.

Fundamentação teórica: Coeficiente

FUNDAMENTAÇÃO TEÓRICA

$$v_i \leftarrow \chi \left[v_i + U(0, \phi_1) \odot (p_i - x_i) + U(0, \phi_2) \odot (p_g - x_i) \right]$$

$$\chi = \frac{2}{\phi - 2 + \sqrt{\phi^2 - 4\phi}}, \quad \phi = \phi_1 + \phi_2 > 4$$

Configuração clássica

$$\begin{aligned} \phi &= 4,1 \\ \phi_1 &= \phi_2 = 2,05 \end{aligned}$$

Construção

$$\chi \approx 0,7298$$

Coeficientes efetivos

$$\chi \cdot 2,05 \approx 1,49618$$

Resultado importante: a construção fornece uma forma principiada de controlar estabilidade e convergência.

Fundamentação teórica: A topologia é parte do algoritmo

FUNDAMENTAÇÃO TEÓRICA


A topologia define quem informa quem e, portanto, como boas soluções se propagam pelo enxame.

Informação rápida

Topologias mais conectadas disseminam rapidamente uma boa descoberta.

Convergência

Mais conectividade pode acelerar convergência, mas também aumentar a atração por ótimos locais.



Diversidade


Topologias mais esparsas retardam o consenso e preservam buscas paralelas.

Problema-dependência

O efeito da topologia depende da função e do modo de interação entre partículas.

Fundamentação teórica: gbest, lbest e von Neumann

FUNDAMENTAÇÃO TEÓRICA



gbest (Estática, Global)




Todas as partículas têm acesso à melhor solução encontrada pelo enxame até o momento.



Vantagem:
convergência rápida.



Risco:
maior vulnerabilidade a ótimos locais.



lbest (Estática, Local)




Cada partícula interage apenas com vizinhos diretos na vizinhança local.



Vantagem:
maior diversidade e busca paralela.



Risco:
convergência mais lenta.



Von Neumann



Topologia em grade ortogonal. Cada partícula possui uma vizinhança local tipicamente com 4 vizinhos.



Vantagem:
bom compromisso entre propagação da informação e diversidade.



Observação:
o desempenho depende do problema; não há topologia universalmente ideal.


O artigo não identifica uma topologia universalmente melhor: o efeito depende do problema e do modo de interação.

Fundamentação teórica: FIPS e variantes

FUNDAMENTAÇÃO TEÓRICA

FIPS · Fully Informed Particle Swarm

No PSO canônico, a influência social é concentrada no melhor vizinho. No FIPS, múltiplos vizinhos contribuem para o movimento.



Outras linhas de evolução do PSO

Binary PSO

Espaços binários

Dynamic PSO

Funções que mudam no tempo

Noisy PSO

Avaliações com ruído

Hybrids

GA, DE, ACO, hill-climbers

Diversity control

Evitar convergência prematura

Bare-bones

Movimento por distribuições

Fundamentação teórica: Limites da teoria do PSO

FUNDAMENTAÇÃO TEÓRICA

1

Modelos determinísticos

Autovalores, estabilidade e convergência sob hipóteses simplificadoras.

2

Modelos estocásticos

Lyapunov, distribuições de velocidade e modelos de cadeia de Markov.

3

Modelos executáveis

Simulações para estudar comportamento emergente, topologia e interação com a fitness landscape.


Limitação estrutural

**Um PSO real combina muitas partículas, memória adaptativa, forças aleatórias e uma função objetivo específica.
Um modelo matemático completo é difícil.**

Metodologia: Como o artigo organiza a revisão

METODOLOGIA

Não há um único dataset ou experimento central. A “metodologia” é a organização crítica da literatura de PSO.



O próprio artigo descreve essa sequência logo no início.

Aplicações analisadas

Os autores categorizam mais de 700 trabalhos de aplicação encontrados no IEEE Xplore da época.

Escopo assumidamente parcial

Os autores dizem que o artigo deve ser visto como uma “fotografia” de sua perspectiva em 2007.

Metodologia: reprodução didática em Jupyter

METODOLOGIA

Objetivo: verificar visualmente como parâmetros afetam convergência e estabilidade.

$$f(x) = \sum_{j=1}^2 \left[x_j^2 + 10 (1 - \cos(2\pi x_j)) \right]$$

Espaço de busca

$x_1, x_2 \in [-5, 12; 5, 12]$
Função Rastrigin 2D
Ótimo global em (0,0)

Enxame

30 partículas
80 iterações
Mesma seed = 2

Métricas


Melhor fitness
Trajetórias
Módulo médio da velocidade

Reprodutível

Notebook
Python +
NumPy

Metodologia

METODOLOGIA



Metodologia: três configurações comparadas

METODOLOGIA

A · Constrição

Estável

$$\chi = 0,7298$$

$$c_1 = c_2 = 1,49618$$

Referência canônica do artigo

B · Inércia decrescente

Adaptativa

$$\omega: 0,9 \rightarrow 0,4$$

$$c_1 = c_2 = 2,0$$

Exploração → refinamento

C · Agressiva

Instável

$$\omega = 1,2$$


$$c_1 = c_2 = 2,5$$

Sem clamp de velocidade

Hipótese didática: A e B devem convergir; C deve apresentar crescimento excessivo de velocidade e pior desempenho.

Resultados: o enxame se concentra no ótimo global

RESULTADOS



Configuração A · construção

Melhor fitness final

2.70×10^{-8}


Melhor posição

$x_1 \approx -6,0 \times 10^{-6}$
 $x_2 \approx -1,0 \times 10^{-5}$


As trajetórias não são lineares: as partículas oscilam e refinam a região à medida que pbest e gbest são atualizados.

Resultados: parâmetros mudam a dinâmica do enxame

RESULTADOS



Melhor fitness final **A: $2.70e-8$ B: $2.97e-7$ C: 6.48**



Velocidade média final **A: 0.45 B: 0.78 C: $7.22e+8$**

A configuração agressiva não apenas converge pior: a velocidade explode em várias ordens de grandeza.

Resultados da revisão: onde PSO foi aplicado?

RESULTADOS

Os autores analisaram mais de 1100 publicações no IEEE Xplore; cerca de 700 foram classificadas como aplicações de PSO.

Imagem e vídeo 51	Redes elétricas / despacho 48	Controle 47	Eletrônica / EM 39
Antenas 39	Sistemas de potência 39	Scheduling 38	Redes de comunicação 30
Classificação / data mining 29	Robótica 23	Sensores / sensor networks 13	Finanças / economia 7

Número de trabalhos por categoria na base analisada pelos autores, não uma medida de desempenho do PSO.

Análise crítica: pontos fortes e limitações

ANÁLISE CRÍTICA DO TRABALHO

Pontos fortes

- Panorama amplo e organizado do PSO
- Integra algoritmo, topologia, teoria e aplicações
- Explicita a evolução das técnicas de estabilidade
- Reconhece problemas em aberto em vez de apresentar o método como resolvido

Limitações

- É uma fotografia da área em 2007
- Não há benchmark experimental sistemático entre todas as variantes
- Vários modelos teóricos dependem de simplificações fortes
- Resultados de topologia e parâmetros são dependentes do problema

Uma boa crítica distingue limitações do artigo de limitações intrínsecas do PSO.

Análise crítica: Questões abertas e Possíveis direções

ANÁLISE CRÍTICA DO TRABALHO



QUESTÕES ABERTAS (2007)



Parâmetros

Não havia consenso sobre valores universais para ω , ϕ_1 , ϕ_2 ou χ para diferentes problemas.



Topologia

Qual estrutura de vizinhança oferece o melhor compromisso entre velocidade e diversidade?



Memória

Impacto de estratégias de memória além de *pbest* e *gbest* (ex.: múltiplas memórias, reinicialização).



Convergência

Provas gerais de convergência para o ótimo global ainda não estavam disponíveis.



Inicialização e parada

Falta de regras sistemáticas para inicialização e critérios de parada robustos.



POSSÍVEIS DIREÇÕES / MELHORIAS



Parâmetros autoadaptativos

Ajustar ω , ϕ_1 , ϕ_2 ou χ dinamicamente conforme o estado do enxame e da paisagem de busca.



Topologias dinâmicas

Permitir que a estrutura de vizinhança evolua ao longo da execução para balancear exploração e exploração.



Mecanismos de diversidade

Manter a diversidade do enxame com técnicas como crowding, repulsão ou reinicialização parcial.



Múltiplos enxames / cooperação

Uso de subenxames ou ilhas para explorar regiões distintas do espaço de busca.



Memória adaptativa

Estratégias de memória mais ricas: múltiplos *pbest*, memória de longo prazo ou memória baseada em nichos.



Essas direções seguem sendo **ativas** até hoje e impulsionaram a evolução contínua do PSO após 2007.

Conclusão

CONCLUSÃO

- | | | |
|---|----------------------------|---|
| 1 | PSO é populacional | Várias soluções são exploradas simultaneamente. |
| 2 | Memória + sociedade | pbest e vizinhança orientam o movimento. |
| 3 | Parâmetros importam | ϕ_1 , ϕ_2 , ω e χ alteram estabilidade e busca. |
| 4 | Topologia importa | A rede de comunicação muda a velocidade do consenso. |
| 5 | PSO é uma família | Variantes expandem o método para diferentes problemas. |

A força do PSO não está em uma partícula individual, mas na interação entre memória, movimento e informação social.

Perguntas?

Referências

REFERÊNCIAS

1. POLI, R.; KENNEDY, J.; BLACKWELL, T. Particle swarm optimization: An overview. *Swarm Intelligence*, 1, 33–57, 2007. DOI: 10.1007/s11721-007-0002-0.
2. KENNEDY, J.; EBERHART, R. C. Particle swarm optimization. *Proceedings of the IEEE International Conference on Neural Networks*, 1995.
3. CLERC, M.; KENNEDY, J. The particle swarm: explosion, stability, and convergence in a multidimensional complex space. *IEEE Transactions on Evolutionary Computation*, 6(1), 58–73, 2002.
4. SHI, Y.; EBERHART, R. C. A modified particle swarm optimizer. *IEEE International Conference on Evolutionary Computation*, 1998.
5. Notebook do seminário: reprodução didática própria da dinâmica do PSO em função multimodal bidimensional.

Obrigado!

Quiz - 1º Seminário



<https://forms.cloud.microsoft/Pages/ResponsePage.aspx?id=USyefs-fLk-nmwl-UqQkzUyY0qlxJGIMnBH3YP-fAcxUREk3UzIwUEI4RFU4WIE3UVZTUFhNTEZIVS4u>

Inatel